

Reglas del TP:

- Este trabajo debe hacerse de a dos o de a tres.
- Deben enviarse el script de R y un informe que contenga las respuestas a todas las preguntas y los gráficos pedidos en RMarkdown. No hace falta explicar en el informe que es lo que hace cada una de las funciones del script.
- El informe y el script deben estar prolijos. Esto en particular implica que las variables tienen que tener un nombre descriptivo (es decir, no llamar `a`, `b`, `c` a las variables).

Regresión ordinal



Vamos a usar un conjunto de datos correspondiente a una encuesta con escala de tipo Likert (es decir, se pide al encuestado marcar un entero entre 1 y 5, donde 1 = Totalmente en desacuerdo y 5 = Totalmente de acuerdo). La encuesta consiste de 44 preguntas muy variadas, como "Disfruto de bailar" o "Creo que un desastre climático podría llegar a ser divertido". Para los individuos encuestados, se tienen también otras variables extra-encuesta que pueden ser de interés, como por ejemplo edad, género, religión, etc. Los datos están `encuesta.csv` y el archivo `codebook.txt` contiene una descripción de las preguntas y las variables extra-encuesta.

1. Dividir al conjunto de datos en data de entrenamiento y testeo.
2. Leer las preguntas y elegir alguna que parezca interesante. Llamaremos Q a esta pregunta.
3. Supongamos que queremos modelar la respuesta Q en función de la edad y el género. ¿Cuál sería el problema teórico de usar una regresión lineal para esto? ¿Cuál sería el problema de usar una regresión multinomial en este problema?

4. Leer (en Wikipedia, usando IA, o como prefieran) acerca de **Regresión Ordinal**. Explicar, en sus propias palabras, en qué consiste este modelo.
5. Usando el paquete `MASS` y la función `polr`, aplicar el modelo de regresión ordinal para predecir Q en función de la edad.
6. Estimar la probabilidad de que a una persona de 25 años esté **al menos** de acuerdo con la frase "me gustan las armas" (pregunta 9).
7. Para la pregunta Q , definamos la siguiente función de pérdida:

$$L(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

donde y_i es la respuesta del individuo i a la pregunta Q y \hat{y}_i es la correspondiente predicción. Notar que tanto y_i como \hat{y}_i son números enteros entre 1 y 5. Implementar esta función de pérdida en R.

8. Implementar un modelo lineal que prediga la respuesta a la pregunta Q en función de la edad. Este modelo tendrá predicciones \hat{y} que pertenecen a toda la recta real. Para hacerlo comparable con el modelo de regresión ordinal, tomar como predicción final al número entero entre 1 y 5 más cercano a y_i .
9. Comparar el valor de la pérdida L para el modelo de regresión ordinal y el modelo de regresión lineal (modificado) del item anterior, aplicando ambos. Decidir cuál de los dos es preferible (recordar entrenar los modelos en el conjunto de entrenamiento y evaluarlos en la data de testeo).
10. Vamos a intentar predecir la respuesta a la pregunta Q únicamente con la edad. Sea β el coeficiente correspondiente a la edad. Vamos a plantear un modelo bayesiano usando la función `stan_polr` del paquete `rstanarm`, en donde le vamos a imponer una distribución a priori a β . Mostrar cómo dicha elección de la priori afecta la probabilidad a posteriori de dicho parámetro. Es decir, mostrar un conjunto de distribuciones a priori que induzcan probabilidades a posteriori muy distintas. (Comparar estas posteriores en un gráfico sería lo ideal).
11. (Opcional) Implementar un modelo de regresión ordinal bayesiano únicamente usando el paquete `rstan`.

Importante / para discutir: en general puede ser problemático plantear modelos que usen al género, raza, religión, etc. como covariables. La data de entrenamiento representa al status quo, que puede reflejar sesgos discriminatorios en ciertos grupos. El modelo justamente tiende a aprender a reproducir esos sesgos. En este TP se pueden usar, pero en general hay que tener cuidado.